机器学习第三次作业

1. 硬间隔 SVM 的最优超平面计算

给定二维样本集：

样本	特征 (x_1, x_2)	标签 y
A	$(0, 0)$	+1
B	$(1, 1)$	−1
C	$(2, 0)$	-1

（1）写出线性可分 SVM 的优化目标函数（原始形式）。

（2）画出这些点在平面上的分布，并给出直观的分界线方向。

（3）将该问题化为拉格朗日对偶问题，求出支持向量与对偶变量 α_i的非零条件。

（4）求出最优分离超平面方程 $w^{\top}x + b = 0$。

（5）计算分类间隔的宽度。

答：

2. 核函数与软间隔分析

已知 SVM 的对偶形式为：

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2}\sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

约束：$\sum_i \alpha_i y_i = 0, 0 \le \alpha_i \le C$

（1）若使用高斯核 $K(x_i, x_j) = e^{-\|x_i - x_j\|^2}$，说明此核在特征空间的非线性映射性质；

（2）分析参数 C 过大或过小时对应“欠惩罚”和“过惩罚”的几何后果；

(3)给出硬间隔与软间隔 SVM 的几何差别示意(可用文字或符号说明支持向量位置变化);

(4)说明核函数必须满足的两个条件。

3. 决策树构建与剪枝分析

给定以下训练数据集(二维离散特征):

样本	天气	湿度	是否打球(标签)
A	晴	高	否
B	晴	正常	是
C	阴	高	是
D	阴	正常	是
E	雨	高	否
F	雨	正常	是

(1) 计算在主节点上按“天气”划分时的信息增益,并判断是否是最优划分特征。
(2) 画出对应的决策树结构(可用文字层次描述代替图形)。
(3) 若使用“基尼指数”作为划分标准,比较与信息增益的划分结果是否一致。

4. 机器学习综合题

某银行希望利用机器学习模型自动评估客户的信用风险。每位客户的特征如下：

特征	类型	说明
收入水平	高 / 中 / 低	分类特征
年龄	连续型	（单位：岁）
是否有房	是 / 否	分类特征
历史违约次数	连续型	（次）
信用风险标签	0 = 低风险，1 = 高风险	模型预测目标

银行提供了如下 6 组训练样本（简化数据）：

编号	收入水平	年龄	是否有房	违约次数	信用风险
1	高	45	是	0	0
2	低	23	否	2	1
3	中	32	否	1	1
4	高	36	是	0	0
5	中	40	否	0	0
6	低	29	否	1	1

(1) 请给出：将“收入水平”（高/中/低）和“是否有房”（是/否）转换为数值的合理编码方式（例如 0/1 或 One-Hot 等形式）；编码后第 2 条样本的特征向量应为何？（按顺序：收入、年龄、是否有房、违约次数）。

(2) 若模型首先考虑以“收入水平”作为划分属性（高、中、低），求此划分的信息增益。请写出计算过程，并说明最终是否选择“收入水平”作为首个划分节点（可定性判断）。

(3) 假设二分类问题中，采用支持向量方法，当惩罚系数 C 较大时，会对模型的间隔与误分类率产生怎样的影响？简要说明。

(4) 考虑一个简化的两层前馈神经网络：

输入层节点：2（收入编码与违约次数）

隐藏层节点：2，使用 Sigmoid 激活函数

输出层节点：1，使用 Sigmoid 输出（表示高风险概率）

已知：$x = [1, 2]^T$，$W_1 = \begin{bmatrix} 0.5 & -0.4 \\ 0.3 & 0.1 \end{bmatrix}$，$b_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$，$W_2 = \begin{bmatrix} 0.6 \\ -0.2 \end{bmatrix}$，$b_2 = 0$

请计算：隐藏层输出 $h = \sigma(W_1 x + b_1)$；最终输出 $\hat{y} = \sigma(W_2^T h + b_2)$。

（其中 $\sigma(a) = \frac{1}{1+e^{-a}}$，保留两位小数即可）

（5）结合本任务特征特点与数据量（仅约 100 条样本），分析：若仅能选择 决策树 / SVM / 神经网络 三种之一，你会选择哪种？请从数据规模、特征类型、模型可解释性 三方面说明理由。