机器学习第二次作业

1. AdaBoost 权重更新与样本分布变化

给定一个二分类数据集：

样本	x_i	标签 y_i
1	A	+1
2	B	+1
3	C	-1
4	D	-1

第一个弱分类器 $h_1(x)$ 的预测如下：

样本	$h_1(x_i)$
A	+1
B	-1
C	-1
D	+1

已知错误率 $\varepsilon_1 = 0.25$。

(1) 计算弱分类器权重：$\alpha_1 = \frac{1}{2}\ln\frac{1-\varepsilon_1}{\varepsilon_1}$

(2) 计算新的样本分布 $D_2(i)$。

(3) 请分析哪些样本的权重会上升？这意味着 AdaBoost 下一轮学习时会偏向哪些样本？解释其原因。

2. Bagging 模型方差与集成优点

某回归问题中，单个基学习器的输出方差为 $Var(T_i) = 1.2$，不同学习器之间的预测相关系数为 $\rho = 0.2$。共有 $N = 50$ 个学习器。

(1) 计算集成预测输出的总体方差：$Var(\bar{T}) = \rho Var(T_i) + \frac{1-\rho}{N} Var(Ti)$

(2) 若改为 $N = 200$ 个学习器，新的方差是多少？

(3) 结合计算结果，Bagging 模型减少方差的机制是什么？为何当学习器越多、相关性越低时效果越好？

3. PCA 主成分方向与投影

给定数据集如下，每一行是一条样本：

$$X = \begin{bmatrix} 2 & 0 & 1 \\ 3 & 1 & 2 \\ 4 & 0 & 3 \\ 5 & 2 & 4 \\ 6 & 3 & 5 \end{bmatrix}$$

(1) 求特征值与特征向量，，并将特征向量进行单位化。

(2) 指出主成分方向，并计算方差贡献率。

(3) 对样本 $x = [4, 0, 3]^T$，计算其在第一主成分上的投影。

(4) 如果仅保留第一主成分，原始三维信息会损失多少？此损失代表什么含义？

4. K-Means 聚类迭代与收敛分析

一维数据集：

$$\mathrm{x} = \{1,2,3,10,11,12\}$$

初始化：

$$\mu_1 = 2, \quad \mu_2 = 10$$

(1) 执行两次完整的 K-Means 迭代，每次写出簇分配与新的中心。

(2) 说明两步后算法是否收敛。

(3) 若初始中心改为 $\mu_1 = 3, \mu_2 = 12$，结果会怎样变化？为什么 K-Means 对初始化敏感？